Simulacija Okeana Pomoću Brze Fourierove Transformacije (FFT)

Teorijska Objašnjenja i Matematički Model

Na osnovu rada Jerryja Tessendorfa (*Simulating Ocean Water*)

Simulacija okeana pomoću brze Fourierove transformacije (FFT - Fast Fourier Transform) zasniva se na radu Jerryja Tessendorfa (1999. – 2004.) godine ("Simulating Ocean Water"), koji predstavlja standard u filmskoj industriji i naprednim video igrama (npr. *Titanic*, *Sea of Thieves*).

1 Oznake koje se koriste

Oznaka	Značenje
N	Broj tačaka mreže po jednoj osi (mreža je $N \times N$, N je stepen dvojke)
L	Fizička veličina kvadratnog dijela (patch-a) površine u metrima
$\boldsymbol{x} = (x, z)$	Horizontalna pozicija na površini
$\boldsymbol{k} = (k_x, k_z)$	Talasni vektor; $k = \lvert\boldsymbol{k}\rvert$ je njegov intenzitet
$h(\boldsymbol{x}, t)$	Visina površine u tački $\boldsymbol{x}$ u trenutku t
$\tilde{h}(\boldsymbol{k}, t)$	Kompleksna amplituda talasa sa talasnim vektorom $\boldsymbol{k}$ (spektar)
$\omega(k)$	Kružna frekvencija talasa
$g \approx 9.81$ m/s^2	Gravitaciono ubrzanje
V, $\hat{\boldsymbol{w}}$	Brzina i jedinični vektor smjera vjetra
$L_w = V^2/g$	Najveći talas koji vjetar brzine V može stvoriti
λ	Faktor "choppy" pomaka (nije talasna dužina)

Tabela 1: Pregled osnovnih fizikalnih i matematičkih oznaka.

2 Problem

2.1 Šta je cilj simulacije

Osnovni cilj projekta jeste matematički modelovati i renderovati dinamičnu površinu okeana u svakom trenutku vremena t. Konkretno, za zadatu kvadratnu mrežu dimenzija $N \times N$ tačaka (npr. $256 \times 256 = 65\,536$ tačaka ili $512 \times 512 = 262\,144$ tačaka) na fizičkoj površini veličine $L \times L$ metara, u svakom frejmu animacije potrebno je izračunati tačnu vertikalnu poziciju (visinu) $h(\boldsymbol{x}, t)$ za svaku koordinatu $\boldsymbol{x} = (x, z)$.

Da bi animacija izgledala glatko i prirodno ljudskom oku, cijeli proračun za svih N^2 tačaka mora se izvesti i iscrtati najmanje 30 do 60 puta u sekundi (FPS - *Frames Per Second*). Ovaj zahtjev naziva se simulacija **u realnom vremenu**.

2.2 Zašto je simulacija okeana težak problem

Simulacija velike površine vode u računarskoj grafici predstavlja značajan izazov zbog tri međusobno suprotstavljena zahtjeva:

- **Fizička i estetska složenost (Prirodni realizam):** Stvarni okean nije jednostavan harmonijski talas niti skup od nekoliko pravilnih sinusoida. Površina okeana nastaje preklapanjem **hiljada stohastičkih (slučajnih) talasa** različitih dužina, visina, faza i smjerova kretanja, koje stvara i održava vjetar. Ako simuliramo premalo talasa, površina izgleda plastično, sintetički i ponavljajuće.

- **Zahtjev za brzinom i skalabilnošću:** Kako se povećavaju rezolucija mreže N (radi detaljnije slike) i dimenzija patch-a L (radi prikazivanja većih površina), broj računarskih operacija u svakom frejmu ekstremno brzo raste. Naivni matematički pristupi izračunavanja doprinosa svakog talasa u svakoj tački mreže zahtijevaju milijarde operacija po frejmu, što onemogućava rad u realnom vremenu.
- **Interaktivnost i fizikalna kontrola:** Model ne smije biti samo "slijepa" animacija ili unaprijed snimljeni video. Korisnik ili dizajner mora imati mogućnost da u realnom vremenu mijenja fizičke parametre – poput brzine vjetra V, smjera vjetra $\hat{\boldsymbol{w}}$ ili veličine simuliranog područja L – pri čemu se izgled i ponašanje vodene površine moraju trenutno i prirodno prilagoditi bez ponovnog pisanja algoritma.

2.3 Model visinskog polja (Height Field) i njegova ograničenja

Da bi se postigla brzina potrebna za rad u realnom vremenu, u ovom radu se primjenjuje aproksimacija površine okeana pomoću **visinskog polja (*height field*)**. Površina je predstavljena dvodimenzionalnom skalarnom funkcijom $h(\boldsymbol{x}, t) = h(x, z, t)$, koja svakoj horizontalnoj poziciji (x, z) dodjeljuje tačno jednu vrijednost visine h.

- **Šta dobijamo:** Ova pretpostavka drastično smanjuje dimenzionalnost problema – umjesto simuliranja pune 3D zapremine vode ili miliona slobodnih čestica pod vodenom masom, simulira se samo 2D granična površina između vode i vazduha.
- **Šta gubimo (Ograničenje modela):** Pošto jedna pozicija (x, z) može imati samo jednu visinu h, ovaj model matematički **ne može opisati 3D topološke promjene** kao što su talasi koji se u potpunosti prevrću (lomljenje talasa na obali sa šupljinom unutra), prskanje kapljica ili stvaranje vodene pjene pri sudaru. Prihvatanje ovog ograničenja predstavlja nužan kompromis kako bi se dobila visoka brzina izračunavanja na velikim prostranstvima okeana.

3 Pristupi simulaciji vode i zašto FFT

Da bismo razumjeli zašto se koristi brza Fourierova transformacija (FFT), moramo sagledati kako se uopšte simulira voda u računarskoj grafici. U literaturi (Tessendorf) i praksi postoje tri dominantna pristupa:

1. **Vremensko-prostorna dinamika fluida (CFD)** – simulacija cijele 3D zapremine vode na mreži.
2. **Metode zasnovane na česticama (SPH)** – simulacija vode kao skupa miliona čestica.
3. **Surface-only (površinski) pristupi** – modelovanje samo granične površine vode i vazduha (Gerstnerovi talasi i spektralni FFT pristup).

Pretpostavimo da želimo animirati gustu šumu na vjetru. CFD i SPH pokušavaju simulirati unutrašnju strukturu svakog lista, stabla i strujanje zraka između njih. S druge strane, površinski (spektralni) pristup posmatra samo gornju površinu šume i opisuje njeno talasanje kao zbir jednostavnih valova.

3.1 Dinamika fluida na mreži: CFD (Navier–Stokes)

- **Fizička ideja:** Vodena masa se podijeli na 3D mrežu malih zapreminskih kockica (voksela). U svakoj kockici se rješavaju stvarni fizikalni zakoni – Navier–Stokesove jednačine održanja mase i količine kretanja.
- **Prednosti:** Daje matematički najtačniju fiziku. Izuzetno hvata složene interakcije kao što su udar vala u obalu, pljuskanje vode u čaši ili prevrtanje valova s pretvaranjem u vodenu pjenu.
- **Zašto ne odgovara za naš problem:** Računanje se vrši u cijeloj 3D zapremini. Kako se površina okeana povećava, broj potrebnih 3D kockica raste kubno (N^3). Tessendorf navodi da je nemoguće na ovaj način obraditi prostranstvo zaliva ili otvorenog mora u realnom vremenu uz zadržavanje detalja kapljica.

3.2 Simulacija pomoću čestica: SPH (Smoothed Particle Hydrodynamics)

- **Fizička ideja:** Fluid se posmatra kao skup velikog broja diskretnih čestica koje lebde u prostoru i međusobno djeluju privlačnim i odbojnim silama.
- **Prednosti:** Ne zahtijeva fiksnu mrežu. Odličan je za lokalne efekte – prskanje vode, eksplozije, vodopade i objekte koji padaju u vodu.
- **Zašto ne odgovara za naš problem:** Za simulaciju mirne, ali ogromne površine okeana potrebne su stotine miliona čestica samo da popune zapreminu ispod površine. Većina tih čestica se i ne vidi (nalaze se u dubini), a troše ogromnu računarsku snagu.

3.3 Gerstnerovi talasi (Zbir kružnih kretanja)

- **Fizička ideja:** Umjesto simuliranja zapremine, posmatramo samo površinske tačke. Dok talas prolazi, svaka tačka na površini kruži u vertikalnoj ravni (opisuje kružnu ili eliptičnu putanju). Za jedan talas amplitude A, talasnog vektora $\boldsymbol{k}$ i početne pozicije $\boldsymbol{x}_0$ važi (Tessendorf, jed. 26–27):

$$\boldsymbol{x} = \boldsymbol{x}_0 - \frac{\boldsymbol{k}}{k} A \sin(\boldsymbol{k} \cdot \boldsymbol{x}_0 - \omega t), \qquad y = A \cos(\boldsymbol{k} \cdot \boldsymbol{x}_0 - \omega t) \tag{1}$$

- **Sabiranje talasa:** Za prirodniji izgled sabira se M ovakvih talasa sa različitim smjerovima i frekvencijama.
- **Ograničenje i računarska cijena:** Da bismo izračunali visinu u svaka od N^2 tačaka na mreži, moramo proći kroz svih M talasa pojedinačno, što daje složenost $O(N^2 \cdot M)$ po frejmu.
  - Ako uzmemo mali broj talasa (npr. $M = 10$), simulacija radi u realnom vremenu, ali voda izgleda vještački, neprirodno i ponavljajuće.
  - Ako želimo stvarni izgled sa hiljadama talasa ($M = 1000+$), algoritam postaje prespor za realno vrijeme.

3.4 Statistički (spektralni) pristup pomoću FFT-a

- **Fizička ideja:** Površina okeana se posmatra kao **zbir svih mogućih sinusoida koje stvara vjetar**. Umjesto da ručno zadajemo talas po talas, koristimo statistički model (spektar) koji odjednom opisuje raspodjelu energije po svim dužinama talasa.
- **Računarski trik (FFT):** Zbir svih tih sinusoida ne računamo pojedinačno, već **svih N^2 talasa sabiramo odjednom** primjenom 2D inverzne brze Fourierove transformacije (IFFT).
- **Dramatično smanjenje cijene:** Cijena izračunavanja opada sa naivnih $O(N^4)$ na samo $O(N^2 \log N)$ operacija po frejmu. Za mrežu 256×256, proračun se ubrzava preko 8.000 puta.
- **Industrijska potvrda:** Ovaj pristup iz 1999. godine omogućio je prve velike simulacije okeana u filmskim hitovima poput *Waterworld* i *Titanic* na mrežama dimenzija 2048×2048.

3.5 Uporedni pregled i zaključak izbora

Zašto je izabran FFT pristup u ovom projektu: Poređenje u tabeli jasno pokazuje da je spektralni FFT pristup jedini model koji ispunjava sva tri ključna zahtjeva postavljena u Poglavlju 2:

1. **Realizam:** Koristi N^2 komponenata (stotine hiljada talasa) utemeljenih na stvarnim mjerenjima vjetra.
2. **Brzina:** Zahvaljujući složenosti $O(N^2 \log N)$, proračun se bez problema izvodi u realnom vremenu.

Pristup	Osnovna ideja	Računarska složenost	Glavno ograničenje
CFD	Fizika fluida u 3D zapremini	Ekstremno velika (N^3)	Neizvodivo za velika prostranstva u realnom vremenu
SPH	Simulacija vode skupom čestica	Vrlo velika (milioni čestica)	Preskupo za mirne, velike površine
Gerstner	Zbir M kružnih talasa	$O(N^2 \cdot M)$	Ili izgleda sintetički (M malo) ili je presporo (M veliko)
FFT Spektralni	**Statistički spektar + IFFT**	$\mathbf{O(N^2 \log N)}$	**Linearni model (nema prskanja i prevrtanja talasa)**

Tabela 2: Uporedni pregled glavnih prilaza simulaciji vode u grafici.

3. **Periodičnost i kontrola:** Generisani kvadratni isječak (patch) se može bešavno popločavati po prostoru, a izgled okeana se trenutno mijenja promjenom fizikalnih parametara vjetra.

Ovim je prikazano zašto je FFT standard za velike površine vode. U narednom poglavlju objašnjavamo kako iz fizike vjetra konstruišemo taj matematički spektar.

4 Spektar talasa: Phillips + slučajni šum

U prethodnom poglavlju smo zaključili da spektralni pristup posmatra okean kao zbir ogromnog broja sinusnih talasa. Ovo poglavlje objašnjava prvi praktični korak algoritma: **kako iz fizike vjetra konstruišemo matematički spektar** i kako iz njega dobijamo početno, zamrznuto stanje okeana u trenutku $t = 0$.

4.1 Prostorni i frekventni domen

Da bismo razumjeli spektralni pristup, moramo razlikovati dva načina prikaza iste vodene površine:

- **Prostorni domen (Spatial Domain):** Opisuje površinu onako kako je vidimo u stvarnosti – svakoj fizičkoj tački na mreži $\boldsymbol{x} = (x, z)$ pridružena je njena trenutna visina $h(\boldsymbol{x}, t)$ u metrima.
- **Frekventni / Talasni domen (Frequency Domain):** Opisuje površinu ne preko tačaka, već preko **pojedinačnih talasnih komponenti** od kojih je sastavljena. Za svaki talasni vektor $\boldsymbol{k}$ znamo njegovu kompleksnu amplitudu $\tilde{h}(\boldsymbol{k}, t)$.

Šta znači kompleksni broj u grafici? Zašto je amplituda $\tilde{h}(\boldsymbol{k}, t)$ kompleksan broj? Kompleksan broj jednim zapisom nosi dvije ključne informacije o talasu:

1. **Modul (intenzitet):** Daje stvarnu **visinu (amplitudu)** tog pojedinačnog talasa.
2. **Argument (ugao/faza):** Daje **trenutnu fazu** talasa – obavještava nas da li je talas u posmatranoj tački na svom vrhu, u dolini ili negdje između.

Prelazak iz frekventnog u prostorni domen (dobijanje visine h iz kompleksnih komponenti) vrši se **inverznom Fourierovom transformacijom (IFFT)**:

$$h(\boldsymbol{x}, t) = \sum_{\boldsymbol{k}} \tilde{h}(\boldsymbol{k}, t)\, e^{i\boldsymbol{k}\cdot\boldsymbol{x}} \qquad \text{(Tessendorf, jed. 36)} \tag{2}$$

4.2 Talasni vektor i diskretna mreža

Talasni vektor $\boldsymbol{k} = (k_x, k_z)$ određuje osobitosti pojedinačnog talasa: njegov pravac pokazuje **smjer kretanja**, a njegov intenzitet $k = |\boldsymbol{k}|$ definisan je preko talasne dužine λ_w kao $k = 2\pi/\lambda_w$. (Veliko k označava kratak talas, dok malo k označava dugačak talas).

Na diskretnoj mreži dimenzija $N \times N$ i fizičkom isječku (patch-u) veličine $L \times L$ metara, talasni vektori i prostorne koordinate uzimaju diskretne vrijednosti:

$$\boldsymbol{k} = \frac{2\pi}{L}(n, m), \qquad \boldsymbol{x} = \frac{L}{N}(n, m), \qquad n, m \in \{-N/2, \ldots, N/2 - 1\} \tag{3}$$

Ovdje je najduži talas koji možemo prikazati ograničen veličinom patch-a ($2\pi/L$), dok je najkraći talas ograničen razmakom između dvije susjedne tačke mreže.

4.3 Statistički model i Phillipsov spektar

Mjerenja na otvorenom okeanu pokazala su da se amplitude talasa ponašaju kao stacionarne, nezavisne Gaussove slučajne veličine. Mjerenjem ne dobijamo tačnu amplitudu za svaki talas, već njegovu **očekivanu prosječnu snagu** $P_h(\boldsymbol{k}) = \langle|\tilde{h}(\boldsymbol{k}, t)|^2\rangle$.

Za talase uzrokovane vjetrom na dubokom moru primjenjuje se **Phillipsov spektar** (jed. 40–41):

$$P_h(\boldsymbol{k}) = A\,\frac{\exp\big(-1/(kL_w)^2\big)}{k^4}\,|\hat{\boldsymbol{k}} \cdot \hat{\boldsymbol{w}}|^2\,\exp(-k^2\ell^2) \tag{4}$$

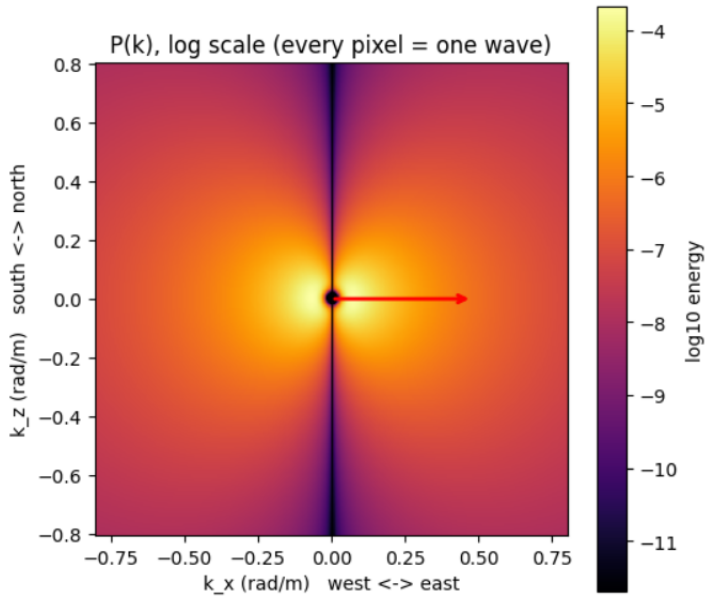
Svaki član u ovoj formuli ima jasnu fizičku ulogu u oblikovanju vode:

Član formule	**Fizičko značenje i uloga u simulaciji**
A	Skalarni faktor amplitude (visina svih talasa srazmjerna je sa $\sqrt{A}$).
$\exp(-1/(kL_w)^2)$	Potiskuje talase duže od $L_w = V^2/g$ (vjetar brzine V ne može stvoriti beskonačno velike talase).
$1/k^4$	Prirodno opadanje energije prema kratkim talasima (sitni valići nose manje energije).
$\lvert\hat{\boldsymbol{k}} \cdot \hat{\boldsymbol{w}}\rvert^2$	Usmjerenost: talasi koji idu u pravcu vjetra $\hat{\boldsymbol{w}}$ dobijaju maksimum energije, a okomiti se potiskuju.
$\exp(-k^2\ell^2)$	Prigušenje izuzetno malih talasa manjih od dužine ℓ (eliminiše šum na visokim frekvencijama).

Tabela 3: Fizička analiza i uloga članova u Phillipsovom spektru.

4.4 Vizuelna analiza Phillipsovog spektra

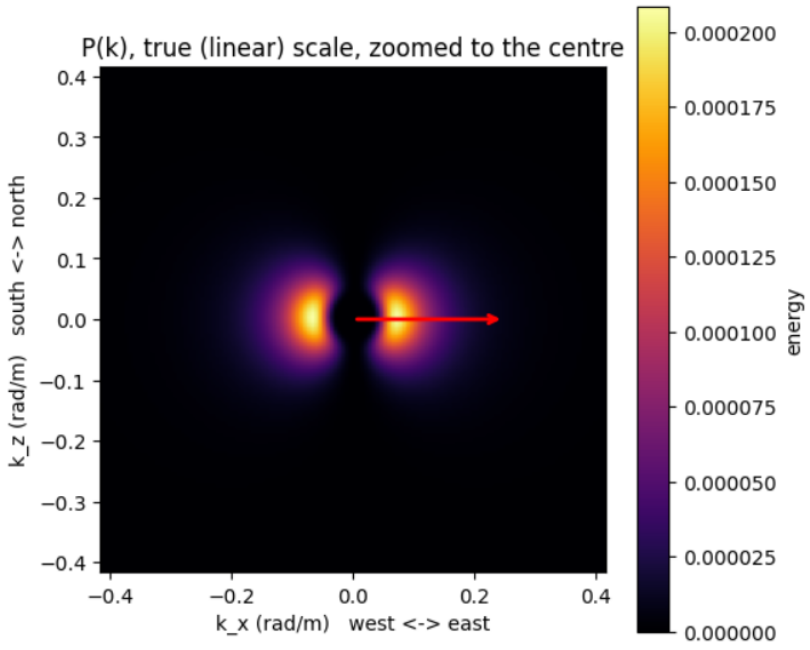
Da bismo razumjeli kako spektar izgleda u memoriji računara, posmatramo Slike 1 i 2. Svaki piksel na slici predstavlja jedan talasni vektor $\boldsymbol{k} = (k_x, k_z)$. Centar slike predstavlja $\boldsymbol{k} = 0$ (najduži talasi), dok udaljavanje od centra označava sve kraće talase.



Slika 1: Phillipsov spektar u logaritamskoj skali.

Logaritamska skala (Slika 1) prikazuje širok raspon energije. Na njoj jasnije uočavamo sljedeće fizikalne efekte:

- **Tamna vertikalna linija ($k_x = 0$):** Talasi okomiti na smjer vjetra imaju energiju nula zbog člana $|\hat{\boldsymbol{k}} \cdot \hat{\boldsymbol{w}}|^2$.
- **Opadanje prema ivicama:** Energija naglo opada pri velikim vrijednostima k.
- **Crna tačka u samom centru:** Član $\exp(-1/(kL_w)^2)$ potiskuje talase beskonačne dužine.



Slika 2: Isti spektar u linearnoj skali (uvećan centralni dio).

Linearna skala (Slika 2) otkriva gdje je koncentrisana glavnina energije:

- Sva energija okeana skupljena je u **dva svijetla režnja** duž ose vjetra. Dva su režnja jer je $P_h(\boldsymbol{k}) = P_h(-\boldsymbol{k})$.
- Najveća energija nalazi se na dominantnoj talasnoj dužini $\lambda \approx 8{,}9\, L_w$. Jači vjetar povećava L_w, pa se režnjevi približavaju centru, što znači da jači vjetar stvara duže talase.

4.5 Slučajni početni spektar ($\tilde{h}_0$)

Phillipsov spektar $P_h(\boldsymbol{k})$ nam daje samo *očekivanu energiju*, ali ne i sam okean. Ako bismo uzeli samo spektar bez slučajnosti, svi talasi bi bili u istoj fazi. Konkretna "realizacija" okeana dobija se unošenjem **Gaussovog šuma** (jed. 42):

$$\tilde{h}_0(\boldsymbol{k}) = \frac{1}{\sqrt{2}} (\xi_r + i\, \xi_i) \sqrt{P_h(\boldsymbol{k})} \tag{5}$$

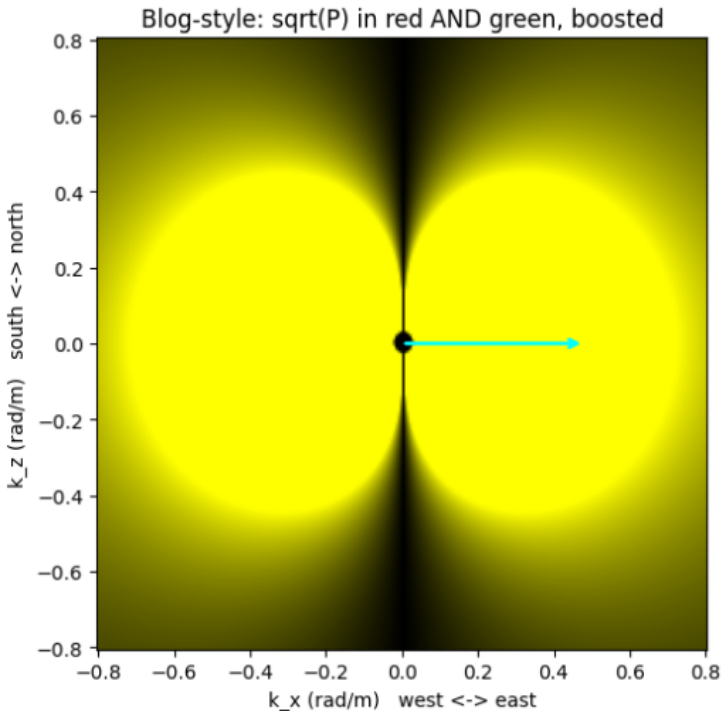
gdje su ξ_r, ξ_i nezavisne slučajne veličine izvučene iz normalne raspodjele sa srednjom vrijednošću 0 i varijancom 1.

Zašto množimo sa $\sqrt{P_h}$, a ne sa P_h? P_h predstavlja **snagu** (kvadrat amplitude). Kako je amplituda jednaka korijenu iz snage, moramo uzeti $\sqrt{P_h}$. Faktor $1/\sqrt{2}$ osigurava matematičku korektnost, tako da očekivana prosječna snaga generisanog signala bude jednaka upravo P_h:

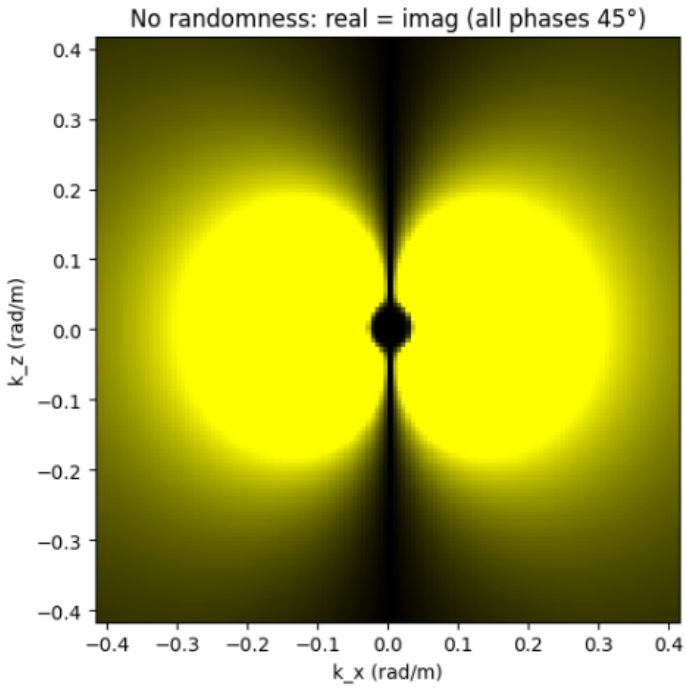
$$\langle |\tilde{h}_0|^2 \rangle = \tfrac{1}{2}\big(\langle \xi_r^2 \rangle + \langle \xi_i^2 \rangle\big) P_h = \tfrac{1}{2}(1+1) P_h = P_h \tag{6}$$

4.6 Vizuelni uticaj Gaussovog šuma na početni spektar

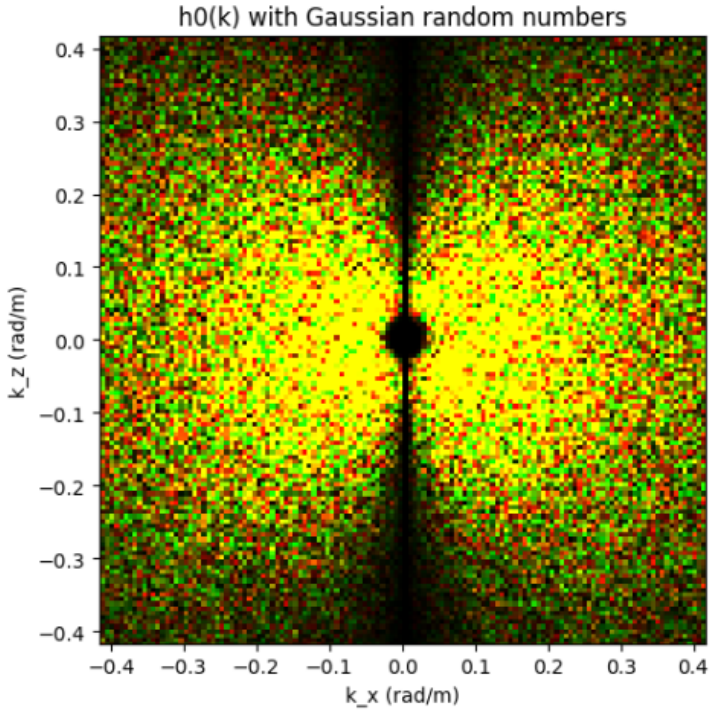
Na Slikama 3–5 prikazan je kompleksni spektar $\tilde{h}_0$ gdje je realni dio prikazan crvenim, a imaginarni zelenim kanalom.



Slika 3: Samo amplituda $\sqrt{P_h(\boldsymbol{k})}$ bez nasumičnih faza.



Slika 4: Spektar bez slučajnosti (faza fiksirana na 45° za sve talase).



Slika 5: Konačni početni spektar $\tilde{h}_0(\boldsymbol{k})$ sa primijenjenim Gaussovim šumom.

- Slika 3 prikazuje samo čistu matematičku amplitudu $\sqrt{P_h}$.
- Slika 4 prikazuje šta se dešava ako je faza fiksirana (svi talasi imaju identičan ugao od 45°, slika je potpuno žuta jer su crveni i zeleni kanal jednaki).
- Slika 5 prikazuje stvarni početni spektar $\tilde{h}_0$. Zahvaljujući Gaussovom šumu, svaki piksel dobija svoju

jedinstvenu fazu i šarenu boju (od crvene do zelene). Iako su faze potpuno nasumične, ukupna prosječna svjetlina i dalje prati fiziku Phillipsovog spektra.

4.7 Izbor praktičnih parametara simulacije

Pri izradi simulacije moraju se pažljivo odabrati fizikalni parametri:

- Rezolucija N bira se kao stepen dvojke ($128, 256, 512, 1024$) zbog zahtjeva radix-2 FFT algoritma.
- Veličina isječka L u praksi iznosi od $10\,\text{m}$ za detaljne valiće do $2\,\text{km}$ za otvoreni okean.
- Veličina mreže L/N mora biti bar 10 do 1000 puta manja od L_w, ali ne ispod $2\,\text{cm}$ (ispod toga nastupaju efekti površinskog napona koje ovaj model ne pokriva).

Na kraju ovog koraka imamo izračunat **početni spektar** $\tilde{h}_0(\boldsymbol{k})$. On u sebi sadrži i fiziku vjetra (spektar) i prirodnu neregularnost okeana (šum). Međutim, ovo je i dalje samo statična slika za $t = 0$. U narednom poglavlju objašnjavamo kako ga pokrećemo u vremenu.

5 Evolucija u vremenu i inverzna FFT

U Poglavlju 4 konstruisali smo početni spektar $\tilde{h}_0(\boldsymbol{k})$ koji predstavlja "zamrznuto" stanje okeana u trenutku $t = 0$. Da bismo dobili animaciju vode, moramo riješiti dva ključna zadatka:

1. **Fizički zadatak:** Izračunati kako se svaki od N^2 talasa kreće i mijenja svoju fazu kako vrijeme t odmiče (disperziona relacija).
2. **Računarski zadatak:** Pretvoriti te podatke iz frekventnog domena nazad u stvarne visine vode u prostornom domenu, i to izvesti dovoljno brzo da se proračun ponovi bar 60 puta u sekundi (Inverzna FFT).

5.1 Disperziona relacija: Zašto se talasi kreću različitim brzinama

U stvarnosti, okeanski talasi se ne kreću svi jednakom brzinom. Iz linearizovanih jednačina hidrodinamike za duboku vodu dobija se **disperziona relacija** koja povezuje kružnu frekvenciju talasa ω sa njegovim talasnim brojem $k = |\boldsymbol{k}|$:

$$\omega(k) = \sqrt{g\,k} \qquad \text{(Tessendorf, jed. 31)} \tag{7}$$

gdje je $g \approx 9{,}81\,\text{m/s}^2$ gravitaciono ubrzanje.

Fizička posljedica (Brzina faze): Brzina kretanja vrha talasa (brzina faze) iznosi $c = \omega/k = \sqrt{g/k}$. Pošto je k obrnuto srazmjeran talasnoj dužini ($k = 2\pi/\lambda_w$), iz ove formule slijedi ključni zaključak:

Duži talasi (manje k) putuju brže od kraćih talasa (veliko k).

Upravo je disperzija razlog zašto se površina okeana stalno mijenja i kreira nove oblike – dugački talasi konstantno pretiču sitne valiće, pa okean nikada ne izgleda kao ukrućena slika koja samo klizi po ekranu.

5.2 Vremenska evolucija spektra u trenutku t

Kako bismo izračunali kompleksnu amplitudu talasa $\tilde{h}(\boldsymbol{k}, t)$ u bilo kojem trenutku t, primjenjuje se formula vremenske evolucije (jed. 43):

$$\tilde{h}(\boldsymbol{k}, t) = \tilde{h}_0(\boldsymbol{k})\, e^{i\omega(k)t} + \tilde{h}_0^*(-\boldsymbol{k})\, e^{-i\omega(k)t} \tag{8}$$

Ova formula ima nekoliko izuzetnih osobina:

- **Dva smjera kretanja:** Prvi član predstavlja talas koji putuje unaprijed u smjeru $\boldsymbol{k}$, dok drugi član (sa konjugovanim spektrom u $-\boldsymbol{k}$) predstavlja talas koji putuje u suprotnom smjeru.
- **Zašto Hermitovska simetrija?** Visina vode u stvarnom svijetu $h(\boldsymbol{x}, t)$ mora biti **čist realan broj** u metrima. U matematici Fourierove transformacije, rezultat IFFT-a je realan samo ako je spektar Hermitovski simetričan: $\tilde{h}^*(\boldsymbol{k}, t) = \tilde{h}(-\boldsymbol{k}, t)$. Drugi član formule izričito osigurava ovu simetriju za svako t, pa se imaginarni dio pri transformaciji automatski poništava.
- **Nezavisnost frejmova (*Embarrassingly parallel*):** Spektar u trenutku t računa se direktno iz početnog stanja $\tilde{h}_0$, bez potrebe da znamo šta se dešavalo u prethodnom frejmu $t-1$. Proračun za svaku tačku $\boldsymbol{k}$ je potpuno nezavisan.

5.3 Problem računske složenosti i Brza Fourierova Transformacija (FFT)

Kada imamo izračunat spektar $\tilde{h}(\boldsymbol{k}, t)$, želimo dobiti visinu $h(\boldsymbol{x}, t)$ u svih $N \times N$ tačaka mreže primjenom inverzne Discrete Fourier Transform (IDFT):

$$h(\boldsymbol{x}, t) = \sum_{\boldsymbol{k}} \tilde{h}(\boldsymbol{k}, t)\, e^{i\boldsymbol{k}\cdot\boldsymbol{x}} \tag{9}$$

Zašto je naivno računanje neizvodljivo? Da bismo izračunali sumu od N^2 sinusoida za samo jednu tačku mreže, potrebno je N^2 operacija. Kako tačaka na mreži ima ukupno N^2, naivni pristup zahtijeva ukupno $N^2 \cdot N^2 = N^4$ operacija po frejmu. Za skromnu mrežu 256×256, to iznosi preko **4,3 milijarde kompleksnih množenja u svakom frejmu**, što bi usporilo animaciju na manje od jednog frejma u sekundi.

Kako radi Cooley–Tukey Radix-2 FFT algoritam: Brza Fourierova transformacija (FFT) rješava ovaj problem principom "podijeli pa vladaj". Ulazni niz dužine N podijeli se na parne i neparne indekse. Transformacije polovina niza E_j (parni) i O_j (neparni) kombinuju se takozvanoj **leptir (*butterfly*) operaciji**:

$$x_j = E_j + W_N^j\, O_j, \qquad x_{j+N/2} = E_j - W_N^j\, O_j \tag{10}$$

gdje je $W_N = e^{+2\pi i/N}$ kompleksni rotacioni faktor. Jedan leptir izračunava dva izlaza odjednom, čime se drastično smanjuje nepotrebno ponavljanje množenja.

5.4 Dvodimenzionalna (2D) FFT

Pošto je 2D transformacija matematički **razdvojiva**, izvodimo je u dva jednostavna prolaza:

1. Prvo se izvede 1D IFFT nad svakim **redom** matrice (N puta po $1D$ IFFT).
2. Zatim se nad rezultatom izvede 1D IFFT nad svakom **kolonom** (N puta po $1D$ IFFT).

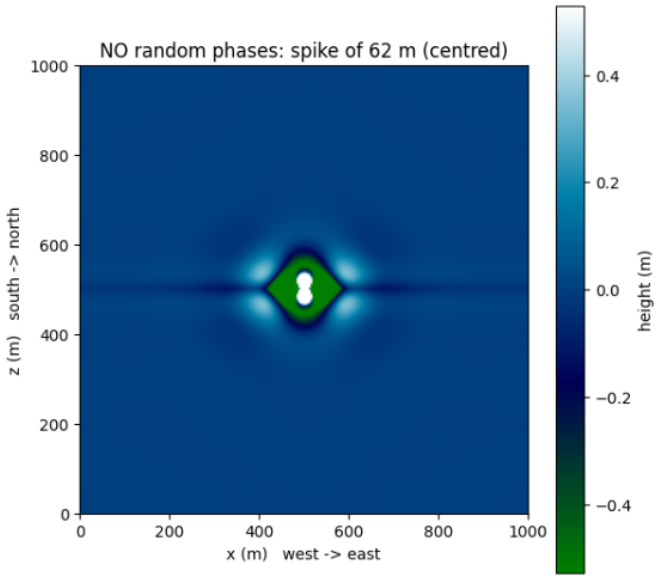
Ukupna složenost iznosi $2N \cdot O(N \log N) = O(N^2 \log N)$.

Postupak proračuna	**Formulska složenost**	**Broj operacija za** $N = 256$
Naivno sumiranje	$O(N^4)$	$\approx 4{,}29 \times 10^9$ (4,3 milijarde)
2D IFFT Algoritam	$\mathbf{O(N^2 \log_2 N)}$	$\approx$ **5,24** $\times$ **10^5 (524 hiljade)**
Odnos broja operacija	**Algoritam je oko** $8.200\times$ **brži u odnosu na naivni pristup!**	

Tabela 4: Poređenje računarske efikasnosti naivnog sumiranja i 2D FFT-a.

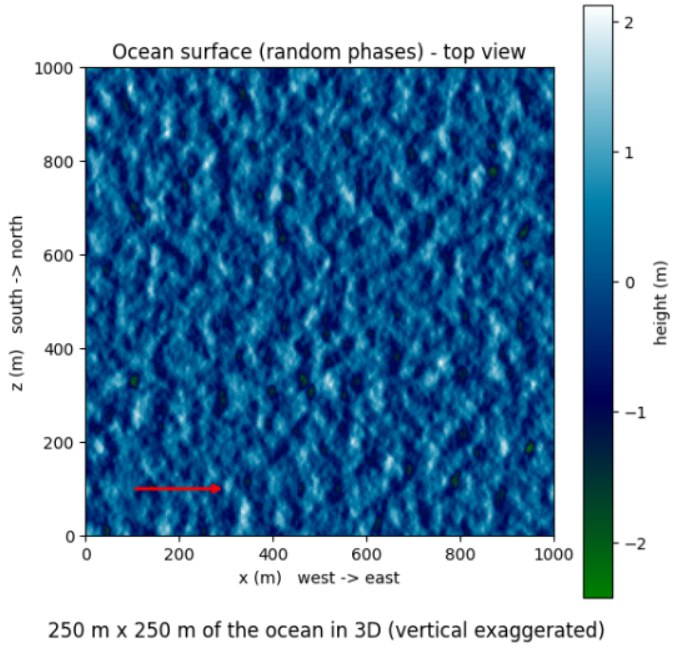
5.5 Eksperimentalni prikaz: Šta IFFT daje i zašto nam treba šum

Kada na izračunati spektar za $t = 0$ primijenimo 2D IFFT, dobijamo visine vode na mreži. Dva eksperimentna primjera na Slikama 6, 7 i 8 jasno pokazuju zašto je Gaussov šum iz Poglavlja 4.5 fizikalno neophodan.

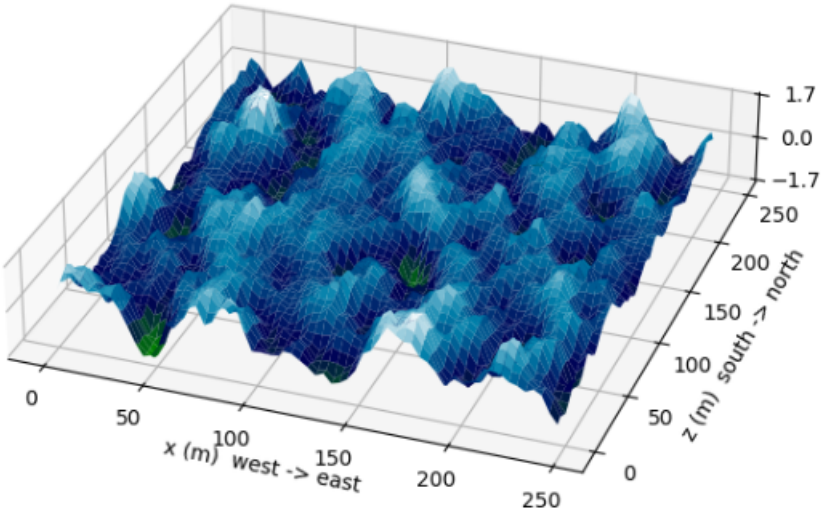


Slika 6: IFFT izveden nad spektrom bez nasumičnih faza.

Slučaj 1: IFFT bez nasumičnih faza (Slika 6): Ako izbacimo Gaussov šum, svi talasi imaju identičnu fazu. U samom centru mreže sve stotine hiljada sinusoida se konstruktivno sabiraju u istoj tački. Rezultat je neprirodna, enormna vertikalna špica visoka čak **62 metra**, dok je ostatak vode potpuno miran. Zbir sinusoida bez faznog pomaka ponaša se kao delta-funkcija (udarac u jednu tačku), što ne opisuje okean.



Slika 7: IFFT sa nasumičnim Gaussovim fazama (pogled odozgo na $1000\,\mathrm{m} \times 1000\,\mathrm{m}$).



Slika 8: 3D prikaz izračunatog visinskog polja na isječku $250\,\text{m} \times 250\,\text{m}$.

Slučaj 2: IFFT sa Gaussovim nasumičnim fazama (Slike 7 i 8): Kada uključimo Gaussov šum, iste te amplitude se na različitim mjestima sabiraju i poništavaju. Dobijamo prirodnu, razuđenu i nepravilnu vodenu površinu sa visinama talasa u fizikalno realnom rasponu od $-1{,}7\,\text{m}$ do $+1{,}7\,\text{m}$.

Ovaj eksperiment prikazuje da **faze talasa diktiraju izgled i prirodnost okeana**, dok **spektar diktira ukupnu energiju**.

Sada imamo brz i funkcionalan algoritam za visinu $h(\boldsymbol{x}, t)$. Međutim, sama visina daje glatku, "plastičnu" površinu. U narednom poglavlju objašnjavamo kako iz istog spektra dobijamo nagibe za osvjetljenje i horizontalne pomake za zaoštravanje vrhova talasa.

6 Iz jednog spektra do površine: Nagibi, Choppy talasi i Osvjetljenje

Poglavlje 5 nam je dalo alat (2D IFFT) i jedno polje — vertikalnu visinu $h(\boldsymbol{x}, t)$. Međutim, sama visina stvara glatku, "plastičnu" površinu koja još uvijek ne podsjeća na pravi okean.

Ključna prednost spektralnog pristupa jeste što se **iz istog izračunatog spektra $\tilde{h}(\boldsymbol{k}, t)$ mogu izračunati sva ostala fizička polja**. Svako dodatno polje dobija se tako što se spektar pomnoži odgovarajućim matematičkim faktorom i propusti kroz istu 2D IFFT transformaciju.

6.1 Visina (Vertikalni pomak)

Visina predstavlja vertikalni pomak tjemena mreže duž y-ose:

$$h(\boldsymbol{x}, t) = \text{IFFT}\big[\tilde{h}(\boldsymbol{k}, t)\big] \tag{11}$$

Zbog Hermitove simetrije opisane u Poglavlju 5, rezultat je čisti realni broj.

6.2 Nagib i normale (Ključ za vizuelni izgled)

Da bismo na površini vode izračunali odbijanje svjetlosti neba i sunca, u svakoj tački moramo znati **vektor normale $\boldsymbol{n}$**. Normala zavisi od nagiba (gradijenta) visinskog polja $\nabla h = (\partial h/\partial x, \partial h/\partial z)$.

Zašto nagib računamo preko FFT-a, a ne konačnim razlikama? U računarskoj grafici nagib se često aproksimira oduzimanjem visina susjednih tačaka mreže (konačne razlike). Međutim, ta metoda loše procjenjuje nagib za kratke talase. U frekventnom domenu, množenje spektra sa $i\boldsymbol{k}$ daje **matematički egzaktan gradijent** za sve talasne dužine (Tessendorf, jed. 37):

$$\nabla h(\boldsymbol{x}, t) = \sum_{\boldsymbol{k}} i\,\boldsymbol{k}\,\tilde{h}(\boldsymbol{k}, t)\,e^{i\boldsymbol{k}\cdot\boldsymbol{x}} \tag{12}$$

Za ovo su potrebne dvije dodatne IFFT transformacije (jedna za parcijalni izvod po x, druga po z). Iz nagiba se normala izračunava kao:

$$\boldsymbol{n} = \frac{(-\partial h/\partial x,\ 1,\ -\partial h/\partial z)}{\sqrt{1 + |\nabla h|^2}} \tag{13}$$

Vizuelni značaj: Ljudsko oko primjećuje vodu primarno preko refleksije svjetlosti, a refleksija zavisi isključivo od normale. Zato slika izračunatih nagiba vizuelno liči na pravu vodu daleko više nego sama slika visina: **visina određuje makroskopski oblik, dok nagib određuje izgled osvjetljenja**.

6.3 Choppy (zaoštreni) talasi

Linearne Fourierove transformacije tvore talase u obliku glatkih, oblih sinusoida. Stvarni okeanski talasi, međutim, imaju **oštre, zašiljene vrhove i široke, ravne doline**.

Tessendorf je ovaj problem riješio uvođenjem horizontalnog pomaka tjemena mreže $\boldsymbol{D}(\boldsymbol{x}, t) = (D_x, D_z)$ (jed. 44):

$$\boldsymbol{D}(\boldsymbol{x}, t) = \sum_{\boldsymbol{k}} -i\,\frac{\boldsymbol{k}}{k}\,\tilde{h}(\boldsymbol{k}, t)\,e^{i\boldsymbol{k}\cdot\boldsymbol{x}}, \qquad \boldsymbol{x}' = \boldsymbol{x} + \lambda\,\boldsymbol{D}(\boldsymbol{x}, t) \tag{14}$$

- Pomak se računa pomoću još dvije IFFT transformacije za komponente D_x i D_z.
- Visina tjemena ostaje nepromijenjena, ali se tjemena mreže horizontalno privlače prema vrhovima talasa, stvarajući oštre grebene i raširene doline.
- Parametar λ je korisnički faktor skaliranja koji kontroliše jačinu efekta.
- **Preklapanje površine (Jacobijan):** Ako se izabere preveliko λ, tjemena se previše približe i površina prolazi sama kroz sebe. To se detektuje kada je Jacobijan preslikavanja $J < 0$ (jed. 45), što se u naprednim simulacijama koristi kao indikator za stvaranje pjene na vrhovima talasa.

6.4 Ukupan broj IFFT transformacija po frejmu

Za kompletno geometrijsko polje u svakom frejmu izvodimo ukupno **5 inverznih 2D FFT-ova**:

1. Visina h (1 IFFT)
2. Nagib po x osi $\partial h/\partial x$ (1 IFFT)
3. Nagib po z osi $\partial h/\partial z$ (1 IFFT)
4. Horizontalni pomak D_x (1 IFFT)
5. Horizontalni pomak D_z (1 IFFT)

Pošto su ulazni spektri realnih polja Hermitovski simetrični, u praksi se po dva realna polja mogu spakovati u jednu kompleksnu IFFT transformaciju, čime se ukupan broj transformacija po frejmu može smanjiti sa 5 na 3.

6.5 Periodičnost i bešavno popločavanje (Tiling)

Zbog prirode Fourierove transformacije, generisani kvadratni isječak (patch) veličine $L \times L$ je **savršeno periodičan na svojim ivicama**. To znači da se isti isječak može ponavljati duž beskonačne ravni poput pločica na podu, bez ikakvih vidljivih šavova ili prekida u talasima.

6.6 Osvjetljenje i vizuelni efekti (Rendering)

Kada imamo geometriju i normale, primjenjuje se model osvjetljenja koji vodi računa o optičkim svojstvima vode:

- **Vektori refleksije:** Zrak svjetlosti koji pada na površinu odbija se u pravcu $\boldsymbol{n}_r = \boldsymbol{n}_i - 2\,\boldsymbol{n}(\boldsymbol{n} \cdot \boldsymbol{n}_i)$, gdje izračunate normale diktiraju odbijanje svjetlosti neba i sunca.
- **Frenelov efekat (Fresnel Effect):** Kada gledamo okomito u vodu, vidimo dubinu pod vodom. Kada gledamo pod oštrim uglom prema horizontu, voda djeluje kao ogledalo. U realnom vremenu primjenjuje se **Schlickova aproksimacija**:

$$R(\theta) \approx R_0 + (1 - R_0)(1 - \cos\theta)^5, \qquad R_0 = \left(\frac{n-1}{n+1}\right)^2 \approx 0{,}02 \tag{15}$$

  gdje je θ ugao između pravca gledanja i normale, a $n \approx 1{,}333$ je indeks prelamanja vode.
- **Odsjaj i nebo:** Dodaju se odsjaj sunca (*specular highlight*) i odraz mape neba (*environment map*), dok se prelazi prema horizontu ublažavaju atmosferskom maglom.

7 Plan realizacije i paralelizacija na CPU/GPU

7.1 Arhitektura paralelnog proračuna

FFT pristup simulaciji okeana je izuzetno pogodan za paralelizaciju (izvršavanje na više procesorskih jezgara ili GPU-u) jer je većina koraka algoritma po svojoj prirodi **paralelna po podacima** (*data parallel*). To znači da se potpuno ista računarska operacija primjenjuje na stotine hiljada tačaka mreže potpuno nezavisno.

Korak algoritma	**Tip paralelizma**	**Objašnjenje**
Generisanje $\tilde{h}_0$	Sekvencijalno	Radi se samo jednom na početku (generator slučajnih brojeva mora biti ponovljiv).
Evolucija $\tilde{h}(\boldsymbol{k}, t)$	Potpuno paralelno	Izračunavanje visine u trenutku t za svako $\boldsymbol{k}$ ne zavisi od drugih tačaka.
2D IFFT (po redovima)	Paralelno po redovima	Svaki red $1D$ FFT-a računa se nezavisno od ostalih redova.
Sinhronizacija	**Barijera**	**Kolone se ne smiju računati dok svi redovi nisu u potpunosti završeni!**
2D IFFT (po kolonama)	Paralelno po kolonama	Svaka kolona se računa nezavisno.
Pomjeranje tjemena	Potpuno paralelno	Svako tjeme na mreži pomjera se za svoj D_x i D_z nezavisno.

Tabela 5: Analiza paralelizacije algoritma po koracima execution-a.

7.2 Ključni pojmovi i izazovi pri paralelizaciji

- **Trivijalno paralelan problem (*Embarrassingly parallel*):** Proračun vremenske evolucije spektra ne zahtijeva nikakvu komunikaciju između niti. Svaka nit na GPU-u ili CPU-u uzme jednu tačku $\boldsymbol{k}$, izračuna novu amplitudu i zapiše je u memoriju bez rizika od konflikta.
- **Problem utrke (*Race Condition*):** Nastaje ako bi više računarskih niti u isto vrijeme pokušalo upisati rezultat u istu memorijsku lokaciju. U našem algoritmu ovaj problem izbjegavamo tako što svaka nit ima strogo dodijeljenu tačku u matrici.
- **Barijera sinhronizacije (*Barrier*):** 2D FFT se izvodi u dva prolaza (prvo svi redovi, pa sve kolone). Između ova dva prolaza mora postojati barijera — tačka u kojoj sve niti čekaju da svi redovi budu završeni. Ako bi neka nit počela računati kolonu prije nego što su ostale niti završile redove, dobili bismo pogrešne podatke.
- **Ubrzanje i Amdahlov zakon:** Teorijsko ubrzanje na p procesorskih jedinica definisano je sa $S = T_{\text{sekv}}/T_{\text{par}}$. Prema Amdahlovom zakonu, ukupno ubrzanje algoritma ograničeno je onim dijelovima koda koji se moraju izvršiti sekvencijalno (npr. alokacija memorije i sinhronizacijske barijere).

7.3 Provjera ispravnosti implementacije

- **Testiranje FFT-a:** Uporediti izlaz FFT algoritma sa sporom DFT referentnom matricom na malim ulaznim signalima (delta-impuls, jednostavni kosinus).
- **Provjera simetrije:** Provjeriti da li je imaginarni dio izračunatih visina blizak nuli (red veličine 10^{-7}).
- **Poređenje sa sekvencijalnom verzijom:** Paralelne CPU i GPU verzije moraju dati identične numeričke rezultate kao i sekvencijalna referentna implementacija.

8 Literatura

1. J. Tessendorf, *Simulating Ocean Water*, SIGGRAPH course notes (1999–2004).
2. O. M. Phillips, *On the generation of waves by turbulent wind*, Journal of Fluid Mechanics, 2(5), 1957.
3. J. W. Cooley, J. W. Tukey, *An algorithm for the machine calculation of complex Fourier series*, Math. Comput., 19(90), 1965.
4. B. Paléologue, *Ocean Simulation with FFT and WebGPU*, blog članak, 2024.
   https://barthpaleologue.github.io/Blog/posts/ocean-simulation-webgpu/

9 Rječnik pojmova

Pojam	Objašnjenje
Amplituda	veličina (visina) talasa; kod kompleksnog broja njegov modul
Butterfly (leptir)	osnovna operacija FFT-a koja spaja dva elementa u dva izlaza
Choppy talasi	talasi sa zaoštrenim vrhovima, postignuti horizontalnim pomakom tačaka
CFD	računarska dinamika fluida (rješavanje jednačina fluida na mreži)
Disperzija	zavisnost brzine talasa od njegove dužine
DFT / FFT / IFFT	diskretna / brza / inverzna brza Fourierova transformacija
Embarrassingly parallel	problem koji se lako dijeli na nezavisne dijelove bez komunikacije
Frejm / FPS	jedna sličica animacije / broj sličica u sekundi
Frekventni domen	opis signala preko amplituda i faza sinusoida
Frenelov efekat	zavisnost refleksije o uglu gledanja
Gaussov šum	slučajne vrijednosti iz normalne raspodjele
Gerstnerov talas	model talasa sa kružnim kretanjem tačaka
Hermitova simetrija	$\tilde{h}^*(\boldsymbol{k}) = \tilde{h}(-\boldsymbol{k})$; osigurava realan rezultat IFFT-a
Jacobijan	determinanta lokalnog preslikavanja; $J < 0$ znači preklapanje (lom) talasa
Kružna frekvencija ω	2π puta frekvencija (rad/s)
Normala	vektor okomit na površinu; koristi se za osvjetljenje
Patch	kvadratni dio površine koji se simulira i koji se može popločavati
Phillipsov spektar	model snage talasa koje stvara vjetar
Prostorni domen	opis površine visinama u tačkama mreže
SPH	hidrodinamika zglađenih čestica
Spektar	raspodjela snage (ili amplituda) po talasnim vektorima
Talasni vektor $\boldsymbol{k}$	smjer kretanja talasa, a intenzitet je $2\pi/$talasna dužina
Visinsko polje	površina opisana visinom u svakoj tački

Tabela 6: Kratak pregled ključnih stručnih pojmova.